

Pengembangan *Soft Sensor* Berbasis LSTM untuk Estimasi Kandungan Etana pada Unit *Deethanizer Column* di *Plant 3 Train G*

Ainul Yaqin^{1*}, Nazrul Effendy², Dwi Joko Suroso³

^{1*,2,3} Departemen Teknik Nukir dan Teknik Fisika FT UGM
Jln. Grafika 2 Yogyakarta 55281 INDONESIA

¹ainulyaqin2019@mail.ugm.ac.id

²nazrul@ugm.ac.id

³dwi.jokosuroso@ugm.ac.id

Intisari— PT Badak LNG Bontang, perusahaan di sektor minyak dan gas, menghadapi fluktuasi komposisi gas umpan setelah penambahan sumber gas *lean* dari Lapangan Merakes pada 2021. Peningkatan kandungan metana dan penurunan hidrokarbon berat, termasuk etana, memunculkan kebutuhan pemantauan komposisi gas yang efisien. Instrumen *Gas Chromatograph* yang digunakan saat ini memerlukan biaya pemeliharaan mahal dan memiliki jeda waktu analisis, sehingga *soft sensor* dipertimbangkan sebagai solusi alternatif yang kontinu. Penelitian ini mengembangkan model *soft sensor* menggunakan arsitektur *Long Short-Term Memory* (LSTM) untuk mengestimasi kandungan etana pada *Deethanizer Column* di *Plant 3 Train G*. Model dilatih menggunakan 2.057 observasi data historis (17 Maret 2022 – 31 Januari 2024) dengan 13 variabel proses sebagai input. Pemrosesan data menggunakan imputasi interpolasi linear, dan urutan waktu dijaga melalui pembagian data secara kronologis serta pembentukan *sequence lookback*. Hasil penelitian menunjukkan bahwa model LSTM dengan konfigurasi dua *layer*, nilai *dropout* 0,2, *hidden size* 32, dan rentang *lookback* 36 *timestep* memberikan performa optimal. Konfigurasi ini menghasilkan nilai pengujian R^2 sebesar 0,9121, RMSE 5,1981, MAE 2,7517, dan Bias 1,2557. Model terbukti mampu mengikuti tren variasi kandungan etana dengan baik, meskipun masih terdapat deviasi ketika nilai aktual target berubah tajam.

Kata kunci— *soft sensor*, LSTM, etana, *deethanizer column*, Badak LNG.

Abstract— PT Badak LNG Bontang, an oil and gas company, faces fluctuations in feed gas composition following the addition of lean gas from the Merakes Field in 2021. The increase in methane and the decrease in heavy hydrocarbons, including ethane, necessitate efficient gas composition monitoring. The currently used Gas Chromatograph requires high maintenance costs and has analytical latency, prompting the consideration of a soft sensor as a continuous alternative solution. This research developed a soft sensor model using a Long Short-Term Memory (LSTM) architecture to estimate the ethane content in the Deethanizer Column at Plant 3 Train G. The model was trained using 2,057 historical data observations (March 17, 2022 – January 31, 2024) with 13 process variables as inputs. Data preprocessing utilized linear interpolation imputation, and temporal order was maintained through chronological data splitting and lookback sequences. The results showed that the LSTM model configured with two layers, a dropout of 0.2, a hidden size of 32, and a 36-timestep lookback delivered optimal performance. This configuration yielded testing metrics of R^2 at 0.9121, RMSE at 5.1981, MAE at 2.7517, and Bias at 1.2557. The model successfully tracked ethane variation trends, although deviations remained when the actual target values changed abruptly.

Keywords— Prediction, Ethane, Soft Sensor, Deethanizer, XGBoost Regression, Badak LNG.

I. PENDAHULUAN

Badak LNG merupakan perusahaan minyak dan gas bumi yang memproduksi gas alam cair (LNG). Tahapan pengolahannya mencakup pemurnian, pengeringan, pemisahan, pendinginan, hingga pencairan gas. Sejak tahun 2017, fasilitas kilang di Bontang menerima tambahan pasokan gas dari Lapangan Jangkrik yang kaya akan metana dan rendah hidrokarbon berat (seperti etana, propana, dan butana). Pasokan gas dengan sifat serupa kembali bertambah pada tahun 2021 dari Lapangan Merakes. Perubahan pasokan ini menyebabkan peningkatan kadar metana hingga 88–90% dan menurunkan gabungan kadar etana, propana, serta butana menjadi di bawah 13%. [1].

Pemantauan komposisi gas pada Plant 3 menggunakan instrumen kromatografi gas (GC). Alat ini memisahkan komponen campuran gas berdasarkan kekuatan ikat molekul

terhadap medium di dalam tabung pengukuran. Komponen dengan daya ikat lemah akan bergerak lebih cepat menuju alat pembaca.[2].

Meskipun GC memberikan hasil pembacaan yang presisi, ketergantungan pada alat fisik ini menimbulkan kendala operasional. GC membutuhkan jadwal perawatan yang padat dan rentan mengalami waktu henti (*downtime*). Pada saat alat berhenti beroperasi, penentuan komposisi gas digantikan oleh uji laboratorium yang memiliki jeda waktu penerimaan hasil yang cukup lama.

Kebutuhan akan data komposisi gas yang terus-menerus mendorong pembuatan *soft sensor*, yaitu sebuah model matematis yang memperkirakan nilai yang sulit diukur secara langsung. Penelitian ini difokuskan pada pembuatan *soft sensor* menggunakan metode *Long Short-Term Memory* (LSTM). LSTM adalah bentuk jaringan saraf buatan yang dirancang khusus untuk mengolah data deret waktu karena mampu

mengenali pola kejadian di masa lalu. Metode ini digunakan untuk menghitung perkiraan kadar etana di dalam unit pemisahan kolom *deethanizer*, Train G, Plant 3 Badak LNG.

Tantangan pemantauan komposisi fluida hidrokarbon secara kontinu menjadi permasalahan dominan di lingkungan pemrosesan *Liquefied Natural Gas* (LNG), di mana penggunaan instrumen analitik fisik konvensional seperti *Gas Chromatograph* (GC) acapkali terhalang oleh latensi pembacaan dan intensitas pemeliharaan yang ekstensif [3]. Dalam konteks ini, pendekatan matematis inferensial yang diejawantahkan melalui *soft sensor* telah mengemuka sebagai solusi rekayasa yang sangat menjanjikan untuk mengisi kesenjangan data operasional akibat limitasi perangkat keras [4]. Penjabaran teoretis secara definitif mengelaborasi peran vital *data-driven soft sensor* di industri proses berskala besar [5]. Kemampuannya untuk mengakuisisi parameter pengukur (seperti metrik temperatur, profil tekanan, dan variasi laju alir) serta mentransformasikannya menjadi estimasi variabel kualitas secara faktual menjadi landasan urgensinya, sebagaimana diaplikasikan pada unit-unit distilasi atau kolom fraksinasi kompleks [6], [7]. Melalui ketersediaan masif dari data *Distributed Control System* (DCS) di pabrik, semesta data historis ini berpotensi besar diutilisasi oleh arsitektur kecerdasan buatan, yang pada akhirnya merevolusi manajemen kualitas operasional dari kerangka reaktif menjadi pemantauan proaktif dan seketika [8], [9].

Konsep kecerdasan representasi (*representation learning*) berbasis data sekuensial kini secara empiris dimanfaatkan untuk menangkap dinamika temporal sistem kimiawi, spesifiknya melalui kapabilitas arsitektur *Long Short-Term Memory* (LSTM) [10], [11]. Pengujian ekstensif metode komputasional non-linear ini secara sistematis mampu memodelkan interaksi sistem multivariabel yang kompleks tanpa harus bergantung seutuhnya pada rumusan prinsip fisika mekanistik (*first-principles*) yang kaku [5], [12]. Sejumlah penelitian terdahulu yang linear dengan tesis ini memperkuat landasan metodologi pembangunan sistem prediksi. Sebagai referensi, kajian yang mendayagunakan analisis *machine learning* untuk memprediksi kadar oksigen gas buang pada *boiler* dan konsentrasi amonia pada unit kristaliser memvalidasi reliabilitas model dalam mengekstraksi informasi di lingkungan proses termal yang dinamis [13], [14]. Selain itu, investigasi spesifik terkait implementasi *deep learning* dan arsitektur sekuensial pada kolom fraksinasi LPG serta pemodelan operasional unit *demethanizer* juga menegaskan kapabilitas algoritma ini dalam menavigasi fenomena jeda waktu (*time-delay*) dari parameter instrumentasi [7], [15]. Relevansi integrasi kajian-kajian empiris ini secara fundamental menopang landasan rekayasa PT Badak LNG untuk mengadopsi metode *soft sensor* dalam menyelesaikan rintangan estimasi fraksi etana pada *deethanizer column* secara presisi.

II. METODOLOGI PENELITIAN

A. Pengantar Pelaksanaan Penelitian

Penelitian ini dilaksanakan untuk mengembangkan *soft sensor* berbasis *Long Short-Term Memory* (LSTM) yang mengestimasi kandungan etana (C₂H₆) pada unit *Deethanizer Column* Plant 3 Train G. Estimasi dilakukan dengan memanfaatkan data historis operasi proses sebagai masukan model. Dengan demikian, model tidak hanya mempelajari hubungan antarvariabel pada satu titik pengamatan, tetapi juga mempelajari pola perubahan variabel proses dari waktu ke waktu.

Penelitian ini dilaksanakan untuk mengembangkan *soft sensor* berbasis *Long Short-Term Memory* (LSTM) yang mengestimasi kandungan etana (C₂H₆) pada unit *Deethanizer Column* Plant 3 Train G. Estimasi dilakukan dengan memanfaatkan data historis operasi proses sebagai masukan model. Dengan demikian, model tidak hanya mempelajari hubungan antarvariabel pada satu titik pengamatan, tetapi juga mempelajari pola perubahan variabel proses dari waktu ke waktu. Gambar 1 menunjukkan alur pelaksanaan penelitian.



Gambar 1. Alur umum pelaksanaan penelitian

B. Pengantar Pelaksanaan Penelitian

Pengolahan data dan pemodelan dilakukan menggunakan bahasa pemrograman Python. Perangkat lunak yang digunakan dipilih berdasarkan kebutuhan khusus, meliputi Pandas untuk pengolahan data tabular, PyTorch untuk model LSTM, MLflow untuk pencatatan eksperimen, serta OpenPyXL untuk pembacaan data Excel. Pelatihan model diarahkan untuk menggunakan GPU jika tersedia, atau beralih ke CPU jika tidak tersedia, tanpa mengubah tahapan penelitian karena hanya memengaruhi perangkat hitung yang digunakan selama proses berlangsung.

C. Data Penelitian

Data penelitian berupa rekaman historis operasi unit *Deethanizer Column* Plant 3 Train G. Data tersebut merepresentasikan kondisi proses dalam rentang 17 Maret 2022 sampai 31 Januari 2024, dengan total 2.057 baris pengamatan. Setiap baris pengamatan memuat waktu pencatatan, tiga belas variabel proses sebagai masukan model, dan kandungan etana (C2H6) sebagai target estimasi. Ringkasan dataset penelitian ditunjukkan pada Tabel I.

TABEL I
RINGKASAN DATASET PENELITIAN

Aspek	Nilai
Periode pengamatan	17 Maret 2022 s.d. 31 Januari 2024
Jumlah baris pengamatan	2.057
Jumlah kolom yang digunakan	15 kolom
Kolom waktu	<i>datetime</i>
Jumlah variabel input	13 variabel proses
Target estimasi	C2H6
Jumlah target kosong	0 baris
Rentang nilai target	0,0000 s.d. 83,9200
Rata-rata target	62,5619
Standar deviasi target	17,8561

Tiga belas variabel input yang digunakan merupakan parameter proses yang berkaitan dengan operasi *de-ethanizer*. Variabel tersebut mencakup laju aliran, level, tekanan, dan temperatur yang secara proses dapat memengaruhi kandungan etana. Daftar variabel input ditunjukkan pada Tabel II.


TABEL II
VARIABEL INPUT MODEL

No.	Kode variabel	Parameter proses	Satuan
1	FIC_06	Laju aliran refluks etana ke 3C-4	kg/h
2	FIC_07	Laju aliran etana ke C2 storage	kg/h
3	FIC_11	Laju aliran bottom product	kg/h
4	FIC_82	Laju aliran etana ke injection	kg/h
5	LIC_05	Level proses fraksinasi bottom product	%
6	LIC_06	Level proses di drum kondensat	%
7	PIC_03	Tekanan keluaran gas etana	psi
8	TI_170	Temperatur uap reboiler bottom product	°C
9	TI_171	Temperatur aliran refluks etana ke 3C-4	°C

C2H6 tidak dimasukkan sebagai variabel input karena digunakan sebagai target estimasi. Dengan pemisahan tersebut, model dilatih untuk memetakan pola historis variabel proses terhadap nilai C2H6 pada titik waktu yang diprediksi.

Mengenai ketersediaan data, seluruh kolom yang digunakan tidak memiliki nilai kosong. Kondisi ini memudahkan proses pra-pemrosesan karena tidak diperlukan penghapusan baris akibat target kosong. Namun, prosedur penanganan nilai kosong tetap disiapkan agar alur penelitian konsisten apabila diterapkan pada data historis lain dengan kondisi yang berbeda.

Tren target terhadap waktu ditunjukkan pada Gambar 2. Grafik ini digunakan untuk memahami pola data sebelum model dilatih, bukan untuk menilai performa model.




Gambar 2. Tren target C2H6 dan batas split kronologis

Gambar 2 menunjukkan bahwa nilai C2H6 berubah sepanjang periode pengamatan. Karena data memiliki karakter deret waktu, seluruh tahapan penelitian mempertahankan urutan kronologis data.

D. Tahapan Pra-pemrosesan Data

Pra-pemrosesan data bertujuan mengubah data historis menjadi tabel numerik kronologis yang siap digunakan untuk pembentukan *sequence* LSTM. Tahap ini dilakukan sebelum pembagian data agar setiap kolom memiliki format yang konsisten dan agar urutan waktu dapat dipertahankan dengan benar. Alur pra-pemrosesan ditunjukkan pada Gambar 3.



Gambar 3. Alur pra-pemrosesan data

Kolom yang digunakan terdiri atas kolom waktu, 13 variabel proses, dan target C2H6. Kolom lain di luar kebutuhan model tidak digunakan dalam pelatihan. Kolom waktu dinormalisasi menjadi format *datetime* agar urutan data dapat dibaca secara kronologis. Seluruh variabel proses dan target dikonversi menjadi nilai numerik. Nilai yang tidak dapat dikonversi diperlakukan sebagai nilai kosong. Data diurutkan berdasarkan waktu pencatatan. Pengurutan ini wajib dilakukan karena LSTM menggunakan urutan historis sebagai dasar pembelajaran.

Strategi utama untuk fitur proses adalah interpolasi linear yang dilengkapi dengan *forward fill* dan *backward fill*. Interpolasi digunakan untuk mengisi celah di bagian tengah deret data, sedangkan *forward fill* dan *backward fill* digunakan untuk mengisi nilai kosong pada bagian tepi deret. Secara ringkas, nilai fitur yang hilang pada waktu t dapat diisi melalui interpolasi linear antara dua titik observasi terdekat:

$$x_t = x_a + \frac{t - a}{b - a}(x_b - x_a), \quad a < t < b \quad (1)$$

Dengan x_a dan x_b merupakan nilai fitur teramati sebelum dan sesudah titik kosong. Jika nilai kosong berada di tepi deret sehingga interpolasi tidak memiliki dua titik pembatas, *forward fill* dan *backward fill* digunakan sebagai pelengkap. Target C2H6 tidak diimputasi. Jika terdapat target kosong, baris tersebut dihapus sebelum pembagian data dan pembentukan *sequence*. Pada dataset penelitian ini, jumlah target kosong adalah 0 baris.

Normalisasi dilakukan menggunakan statistik dari data pelatihan agar data validasi dan tes tidak memengaruhi parameter pra-pemrosesan. Untuk setiap fitur x , normalisasi *z-score* ditulis sebagai:

$$x' = \frac{x - \mu_x}{\sigma_x} \quad (2)$$

Dengan μ_x dan σ_x dihitung hanya dari data pelatihan. Target juga dinormalisasi selama pelatihan:

$$y' = \frac{y - \mu_y}{\sigma_y} \quad (3)$$

Saat evaluasi, prediksi dikembalikan ke skala asli:

$$\hat{y} = \hat{y}'\sigma_y + \mu_y \quad (4)$$

Normalisasi digunakan untuk menstabilkan proses optimisasi karena variabel proses memiliki skala numerik yang berbeda.

E. Pembagian Data Train, Validation, dan Test

Pembagian data dilakukan secara kronologis. Sebanyak 70% baris awal digunakan sebagai data *train*, 15% baris berikutnya sebagai data *validation*, dan 15% baris terakhir sebagai data *test*. Strategi ini dipilih karena penelitian menggunakan data deret waktu, sehingga evaluasi harus dilakukan pada periode yang terjadi setelah periode pelatihan. Tabel III menunjukkan bagaimana data dibagi berdasarkan potongan waktu *sequence*.

TABEL III
PEMBAGIAN DATA DAN *SEQUENCE*

<i>Split</i>	Jumlah baris	Jumlah <i>sequence</i>	Rentang waktu <i>sequence</i>
<i>Train</i>	1.439	1.404	29 Maret 2022 s.d. 9 Juli 2023
<i>Validation</i>	309	309	10 Juli 2023 s.d. 20 Oktober 2023
<i>Test</i>	309	309	21 Oktober 2023 s.d. 31 Januari 2024

Jumlah *sequence* pada data *train* lebih kecil daripada jumlah barisnya karena *sequence* pertama baru dapat dibentuk setelah tersedia 36 *timestep* historis. Pada data *validation* dan *test*, *sequence* tetap dapat dibuat pada setiap endpoint karena konteks historis sebelumnya tersedia dari deret kronologis yang telah diproses.

F. Pembentukan Data Sequence untuk LSTM

Data tabular deret waktu dikonversi menjadi input tiga dimensi agar dapat diproses oleh LSTM. Panjang *lookback* dasar yang digunakan adalah 36 *timestep*, sehingga setiap sampel memuat 36 baris historis dan 13 fitur proses. Dengan bentuk ini, model menerima konteks kondisi proses sebelum menghasilkan estimasi C2H6 pada *endpoint sequence*. Pembentukan *sequence* dilakukan dengan metode *sliding window* yang memungkinkan model mempelajari hubungan antara perubahan variabel proses dan nilai C2H6 pada titik waktu yang diprediksi.


G. Perancangan Model LSTM

Model yang digunakan adalah LSTM satu arah (*unidirectional*) untuk regresi satu target. Model menerima *sequence* fitur proses dan menghasilkan satu nilai estimasi C2H6. Konfigurasi dasar model ditunjukkan pada Tabel IV.

TABEL IV
KONFIGURASI DASAR MODEL LSTM

Komponen	Nilai
Jenis model	<i>Unidirectional LSTM</i>
Jumlah fitur <i>input</i>	13
Panjang <i>sequence</i> dasar	36 timestep
Hidden size dasar	32
Jumlah layer dasar	1
Dropout dasar	0,0
Output	1 nilai estimasi C2H6_G

Struktur komputasi model ditunjukkan pada Gambar 4.



Gambar 4. Struktur komputasi model LSTM

H. Desain Kandidat Eksperimen

Selain konfigurasi dasar, penelitian ini menguji beberapa kandidat pra-pemrosesan dan hiperparameter LSTM. Pengujian kandidat dilakukan untuk mengetahui kombinasi yang memberikan performa validasi terbaik, sedangkan batas utama penelitian tetap sama: model menggunakan LSTM, target C2H6 tidak diimputasi, dan pembagian data dilakukan secara kronologis. Tabel V dan Tabel VI secara berurutan menunjukkan desain dan daftar kandidat eksperimen.

TABEL V
DESAIN KANDIDAT EKSPERIMEN

Kelompok kandidat	Yang dibandingkan	Yang dibuat tetap
Imputasi fitur proses	Interpolasi dengan pelengkap <i>forward/backward fill</i> dan strategi <i>forward/backward fill</i>	Target tidak diimputasi, <i>split</i> kronologis, model LSTM.
Lookback	24, 36, dan 48 <i>timestep</i>	Fitur proses dan target tetap sama.
Kapasitas model	<i>Hidden size</i> 32/64; jumlah layer 1/2; dropout 0,0/0,2	<i>Family model</i> tetap LSTM.
Training	<i>Learning rate</i> , <i>batch size</i> , dan <i>weight decay</i>	<i>Optimizer Adam</i> , <i>loss MSE</i> , <i>early stopping validation</i> .

TABEL VI
DAFTAR KANDIDAT EKSPERIMEN

No.	Kandidat	Perubahan utama
1	Strategi imputasi interpolasi	Fitur proses diisi dengan interpolasi dan pelengkap <i>forward/backward fill</i> .
2	Strategi imputasi <i>forward/backward fill</i>	Fitur proses diisi dengan <i>forward fill</i> dan <i>backward fill</i> .
3	<i>Lookback</i> 24 <i>timestep</i>	Panjang konteks historis dipersingkat menjadi 24 <i>timestep</i> .
4	<i>Lookback</i> 48 <i>timestep</i>	Panjang konteks historis diperpanjang menjadi 48 <i>timestep</i> .
5	<i>Hidden size</i> 64	Kapasitas representasi LSTM diperbesar.
6	Dua layer dengan <i>dropout</i> 0,2	Kedalaman model ditambah dan regularisasi <i>dropout</i> digunakan.
7	<i>Learning rate</i> 0,0005	Laju pembelajaran diperkecil.
8	<i>Learning rate</i> 0,002	Laju pembelajaran diperbesar.
9	<i>Batch size</i> 64	Ukuran <i>mini-batch</i> diperbesar.
10	<i>Weight decay</i> 0,0	Regularisasi <i>weight decay</i> dinonaktifkan.

I. Prosedur Pelatihan Model

Model dilatih dengan optimizer Adam dan fungsi loss Mean Squared Error (MSE). Training dilakukan pada target yang sudah dinormalisasi. Loss MSE pada batch dapat dituliskan sebagai

$$\mathcal{L}_{MSE} = \frac{1}{n} \sum_{i=1}^n (y'_i - \hat{y}'_i)^2 \quad (5)$$

Dengan y'_i dan $\hat{y}'_i$ merupakan target dan prediksi dalam skala normalisasi. Tabel VII menunjukkan konfigurasi dasar untuk proses *training*.

TABEL VII
KONFIGURASI TRAINING DASAR

Parameter	Nilai
<i>Optimizer</i>	<i>Adam</i>
<i>Loss function</i>	<i>Mean Squared Error</i>
<i>Batch size</i> dasar	32
<i>Epoch</i> maksimum	150
<i>Learning rate</i> dasar	0,001
<i>Weight decay</i> dasar	0,0001
<i>Gradient clipping</i>	1,0
<i>Early stopping patience</i>	20 <i>epoch</i>
<i>Seed</i>	42
<i>Runtime device</i>	cuda jika tersedia; <i>fallback</i> ke CPU

Prosedur pelatihan dilakukan sebagai berikut:

1. Menetapkan *random seed* untuk menjaga replikasi eksperimen.
2. Melakukan *forward pass* model untuk menghasilkan prediksi.
3. Menghitung MSE loss pada target yang telah dinormalisasi.
4. Melakukan *backpropagation*.

5. Menerapkan *gradient clipping* untuk membatasi *norm* gradien.
6. Memperbarui parameter menggunakan *Adam*.
7. Menghitung *validation* RMSE dan *validation* MAE pada setiap *epoch*.
8. Menyimpan model dengan *validation* RMSE terendah.
9. Menghentikan pelatihan jika *validation* RMSE tidak membaik selama 20 *epoch*.
10. Membentuk *data loader* untuk pelatihan dengan *mini-batch*.

Data *validation* digunakan untuk memilih model terbaik selama pelatihan. Data *test* tidak digunakan dalam optimisasi maupun pemilihan model, sehingga tetap berperan sebagai data evaluasi akhir.

J. Evaluasi Model

Evaluasi dilakukan pada data *train*, *validation*, dan *test* menggunakan model terbaik berdasarkan *validation* RMSE. Prediksi yang dihasilkan pada skala normalisasi dikembalikan ke skala asli C2H6, kemudian metrik dihitung pada skala asli agar dapat diinterpretasikan sesuai konteks proses. Metrik evaluasi yang digunakan adalah RMSE, MAE, Bias, dan R^2 yang ditunjukkan pada Tabel VIII.

TABEL VIII
METRIK EVALUASI

Metrik	Persamaan	Fungsi
RMSE	$RMSE = \sqrt{\frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{n}}$	Mengukur error kuadrat rata-rata; sensitif terhadap error besar.
MAE	$MAE = \frac{1}{n} \sum_{i=1}^n \hat{y}_i - y_i $	Mengukur rata-rata deviasi absolut.
Bias	$Bias = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$	Mengukur kecenderungan <i>over-estimate</i> atau <i>under-estimate</i> .
R^2	$R^2 = 1 - \frac{\sum (\hat{y}_i - y_i)^2}{\sum (y_i - \bar{y})^2}$	Mengukur proporsi variasi target yang dijelaskan model.

K. Evaluasi Model

Setiap eksperimen mencatat konfigurasi, metrik, riwayat pelatihan, bobot model terbaik, dan prediksi pada setiap *split*. Tabel IX. menunjukkan sejumlah artefak yang disimpan selama proses eksperimen. Pencatatan eksperimen membantu memastikan bahwa hasil penelitian dapat direplikasi dan diperiksa kembali. Pencatatan metrik pada setiap *split* juga memudahkan perbandingan kandidat model.

TABEL IX
ARTEFAK YANG DISIMPAN

Artefak	Isi
Ringkasan eksperimen	Konfigurasi, jumlah baris/ <i>sequence</i> , dan metrik setiap <i>split</i> .
Riwayat pelatihan	Training loss, <i>validation</i> RMSE, dan <i>validation</i> MAE pada setiap <i>epoch</i> .
Bobot model terbaik	Parameter model LSTM dengan <i>validation</i> RMSE terendah.
Konfigurasi run	Salinan pengaturan eksperimen yang digunakan.
Prediksi train	Target dan prediksi pada train <i>split</i> .
Prediksi <i>validation</i>	Target dan prediksi pada <i>validation split</i> .
Prediksi test	Target dan prediksi pada test <i>split</i> .
Ringkasan kandidat	Catatan hasil seluruh kandidat eksperimen.

III. HASIL DAN PEMBAHASAN

A. Pengantar Hasil dan Pembahasan

Model LSTM pada penelitian ini menerima deret waktu variabel proses sebagai masukan dan menghasilkan satu nilai estimasi C2H6 pada titik waktu tertentu. Secara umum, hubungan antara *sequence* input dan prediksi model dapat dinyatakan sebagai

$$\hat{y}_i = f_{\theta}(X_i) \quad (6)$$

Dengan X_i merupakan *sequence* input pada observasi ke- i , $\hat{y}_i$ merupakan estimasi C2H6, dan f_{θ} merupakan fungsi LSTM dengan parameter hasil pelatihan. Pembahasan diarahkan untuk menjawab empat hal utama, yaitu performa konfigurasi awal, dasar perlunya eksperimen kandidat, kemampuan konfigurasi terpilih dalam mengestimasi C2H6, dan pola kesalahan prediksi yang relevan terhadap pengembangan soft sensor pada unit proses.

B. Ringkasan Skenario Eksperimen

Eksperimen menggunakan data historis operasi unit *Deethanizer Column* Plant 3 Train G dalam periode 17 Maret 2022 sampai 31 Januari 2024. Data terdiri atas 2.057 baris pengamatan, 13 variabel proses sebagai input, dan C2H6 sebagai target estimasi. Ringkasan skenario eksperimen ditunjukkan pada Tabel X.


TABEL X
RINGKASAN SKENARIO EKSPERIMEN

Aspek	Nilai
Target estimasi	C2H6
Input model	13 variabel proses
Model	Unidirectional LSTM
Konfigurasi awal (Imputasi Interpolasi)	1 layer LSTM tanpa dropout
Hidden size	32
Lookback	36 timestep
Strategi split	Kronologis
Proporsi split	70% train, 15% validation, 15% test
Strategi imputasi fitur proses	Interpolasi dengan pelengkap forward/backward fill
Kebijakan target	Target tidak diimputasi; baris target kosong dihapus apabila ada
Metrik evaluasi	RMSE, MAE, Bias, R ²
Jumlah kandidat lanjutan	10 kandidat
Kriteria pemilihan	Validation R ² maksimum

C. Hasil Konfigurasi Awal (Imputasi Interpolasi)

Konfigurasi ini menggunakan LSTM satu layer, *hidden size* 32, *dropout* 0,0, *lookback* 36 timestep, *learning rate* 0,001, *batch size* 32, *weight decay* 0,0001, serta interpolasi dengan pelengkap *forward/backward fill* untuk fitur proses. Kandidat awal ini menghasilkan *validation* R² sebesar 0,9279, *test* R² sebesar 0,8955, *validation* RMSE sebesar 8,9258, dan *test* RMSE sebesar 5,6698.

Imputasi Interpolasi telah mampu menjelaskan sebagian besar sebaran C2H6 pada data validasi dan uji, namun kinerjanya belum dianggap cukup tangguh sebagai hasil akhir karena nilai RMSE validasi masih besar serta R² perlu ditingkatkan. Oleh karena itu, percobaan lanjutan dilakukan dengan menguji pengaruh perubahan pra-pemrosesan, panjang lookback, besaran model, regularisasi, serta parameter pelatihan guna mencari pengaturan yang lebih baik tanpa melampaui batasan penelitian.



Gambar 5. Perkembangan metrik Konfigurasi awal (Imputasi Interpolasi) terhadap waktu

Gambar 5 memperlihatkan perkembangan R², RMSE, MAE, dan bias Konfigurasi awal (Imputasi Interpolasi) dalam satu

grafik terhadap waktu pada data test. R² ditampilkan dengan sumbu kanan, sedangkan RMSE, MAE, dan bias ditampilkan dengan sumbu kiri. Metrik dihitung secara kumulatif mengikuti urutan waktu pengamatan, sehingga grafik menunjukkan stabilitas performa awal sepanjang periode uji.


D. Hasil Eksperimen Kandidat dan Pemilihan Konfigurasi Terbaik

Setelah kandidat imputasi interpolasi sebagai konfigurasi awal dievaluasi, penelitian membandingkan beberapa kandidat lanjutan yang berbeda pada strategi imputasi fitur proses dan hiperparameter LSTM. Pengujian kandidat dilakukan karena hasil konfigurasi awal belum menunjukkan performa yang sepenuhnya kuat, terutama pada data *validation* yang masih menyisakan RMSE 8,9258 dan R² 0,9279. Pemilihan model terbaik dilakukan berdasarkan nilai R² pada data *validation*, sedangkan data test tidak digunakan untuk memilih model dan dipertahankan sebagai data holdout untuk menilai performa akhir setelah model terpilih. Hasil kandidat eksperimen ditunjukkan pada Tabel XI.

TABEL XI
HASIL KANDIDAT EKSPERIMEN

No	Kandidat	Fokus perubahan	Validation R ²	Test R ²	Validation RMSE	Test RMSE
1	Konfigurasi awal (Imputasi Interpolasi)	Interpolasi fitur proses pada konfigurasi dasar	0,9279	0,8955	8,9258	5,6698
2	Imputasi forward/backward fill	Forward/backward fill fitur proses	0,9279	0,8955	8,9258	5,6698
3	Lookback 24 timestep	Konteks historis 24 timestep	0,8811	0,8901	11,4621	5,8122
4	Lookback 48 timestep	Konteks historis 48 timestep	0,9224	0,8730	9,2640	6,2482
5	Hidden size 64	Kapasitas hidden state lebih besar	0,9631	0,8905	6,3866	5,8024
6	2 layer dan dropout 0,2	Kedalaman LSTM dan regularisasi dropout	0,9886	0,9121	3,5466	5,1981
7	Learning rate 0,0005	Laju pembelajaran lebih kecil	0,9487	0,8767	7,5277	6,1585
8	Learning rate 0,002	Laju pembelajaran lebih besar	0,9481	0,8896	7,5742	5,8258
9	Batch size 64	Ukuran mini-batch lebih besar	0,8923	0,8954	10,9100	5,6712
10	Weight decay 0,0	Regularisasi weight decay dinonaktifkan	0,9169	0,8661	9,5832	6,4163

Perbandingan Metrik Seluruh Kandidat Eksperimen



Gambar 6. Perbandingan metrik seluruh kandidat eksperimen

Tabel XI dan Gambar 6 menunjukkan perbandingan seluruh kandidat eksperimen dari sisi metrik akhir maupun perkembangan metrik terhadap waktu. Kandidat Imputasi Interpolasi sebagai konfigurasi awal menghasilkan *validation* R^2 sebesar 0,9279 dan *test* R^2 sebesar 0,8955, dengan *validation* RMSE 8,9258 dan *test* RMSE 5,6698.

Model LSTM awal telah menangkap hubungan temporal antara variabel proses dan C2H6 namun diperlukan peningkatan generalisasi agar kinerjanya lebih tangguh. Perbandingan antar-kandidat menunjukkan bahwa penambahan kapasitas dan penerapan regularisasi lebih berpengaruh daripada pemilihan strategi imputasi, karena tidak ditemukan data kosong dalam rangkaian data tersebut. Konfigurasi dua lapis dengan *dropout* 0,2 ditetapkan sebagai pilihan terbaik setelah mencatatkan nilai R^2 tertinggi serta galat validasi dan uji terendah, sehingga akan digunakan untuk analisis lanjutan.

E. Hasil Pelatihan dan Evaluasi Konfigurasi Terpilih

Metrik utama konfigurasi terpilih pada data *train*, *validation*, dan *test* ditunjukkan pada Tabel XII.

TABEL XII
METRIK PERFORMA MODEL TERBAIK

<i>Split</i>	RMSE	MAE	Bias	R^2
Train	3,1412	2,2916	0,4396	0,8953
Validation	3,5466	2,6793	-0,4844	0,9886
Test	5,1981	2,7517	1,2557	0,9121

Untuk membahas kesalahan prediksi, residual didefinisikan sebagai:

$$e_i = \hat{y}_i - y_i \quad (7)$$

Nilai bias pada tabel merupakan rata-rata residual:

$$\text{Bias} = \frac{1}{n} \sum_{i=1}^n e_i \quad (8)$$

Berdasarkan Tabel 5.4, model memperoleh R^2 yang tinggi pada seluruh *split*. Pada data *test*, nilai R^2 sebesar 0,9121 menunjukkan bahwa model mampu menjelaskan sekitar 91,21% variasi C2H6 pada periode uji. Nilai *test* RMSE sebesar 5,1981 dan MAE sebesar 2,7517 menunjukkan bahwa model masih memiliki kesalahan estimasi, tetapi rata-rata kesalahan absolut relatif lebih kecil daripada RMSE. Selisih tersebut mengindikasikan adanya beberapa titik dengan error besar yang meningkatkan nilai RMSE.


Bias *test* bernilai positif sebesar 1,2557. Artinya, pada data uji, prediksi model secara rata-rata sedikit lebih tinggi daripada nilai aktual. Dalam konteks *soft sensor*, bias positif perlu diperhatikan karena estimasi yang terlalu tinggi dapat memengaruhi interpretasi kondisi proses jika model digunakan untuk mendukung pemantauan operasi.

F. Analisis Proses Pelatihan Konfigurasi Terpilih

Riwayat pelatihan digunakan untuk melihat bagaimana konfigurasi terpilih belajar dari data *train* dan bagaimana performanya berubah pada data *validation*. Ringkasan proses pelatihan ditunjukkan pada Tabel XIII.

TABEL XIII
RINGKASAN RIWAYAT PELATIHAN KONFIGURASI TERPILIH

Aspek	Nilai
<i>Epoch</i> maksimum konfigurasi	150
<i>Epoch</i> yang dijalankan	77
<i>Epoch</i> terbaik berdasarkan <i>validation</i> RMSE	57
<i>Validation</i> RMSE <i>epoch</i> 1	36,6659
<i>Validation</i> RMSE terbaik	3,5466
<i>Validation</i> MAE terbaik	2,6793
<i>Validation</i> RMSE <i>epoch</i> akhir	6,1248
<i>Patience early stopping</i>	20 <i>epoch</i>




Gambar 7. Riwayat pelatihan model terbaik

Gambar 7 menunjukkan bahwa error *validation* turun tajam pada fase awal pelatihan, kemudian berfluktuasi sebelum mencapai nilai terbaik. *Validation* RMSE turun dari 36,6659 pada epoch 1 menjadi 6,3569 pada epoch 7, lalu mencapai titik terbaik pada epoch 57 dengan *validation* RMSE 3,5466. Setelah titik tersebut, *validation* RMSE tidak membaik secara konsisten sehingga pelatihan berhenti pada epoch 77 melalui mekanisme *early stopping*.

Pola tersebut menunjukkan bahwa pemilihan model berdasarkan *validation* RMSE bekerja sesuai tujuan. Model yang digunakan untuk evaluasi akhir bukan model pada epoch terakhir, melainkan model pada epoch dengan performa *validation* terbaik. Fluktuasi *validation* RMSE juga wajar pada data proses industri karena hubungan antarvariabel dapat berubah antarperiode operasi dan setiap *batch* pelatihan membawa kombinasi *sequence* yang berbeda.


G. Analisis Prediksi terhadap Data Aktual

Analisis visual dilakukan untuk melihat apakah prediksi model mengikuti pola aktual C2H6. Grafik aktual dan prediksi pada data *validation* serta test ditunjukkan pada Gambar 8 dan Gambar 9.




Gambar 8. Aktual vs prediksi pada *validation split*

Gambar 8 menunjukkan bahwa pada data *validation*, prediksi model secara umum mengikuti pola aktual C2H6. Hal ini konsisten dengan *validation* R^2 sebesar 0,9886. Bias *validation* bernilai -0,4844, yang berarti model sedikit cenderung under-estimate pada periode *validation*, tetapi besar bias tersebut relatif kecil dibandingkan variasi target.



Gambar 9. Aktual vs prediksi pada *test split*

Gambar 9 menunjukkan bahwa pada data test, model masih mampu mengikuti tren utama C2H6. Namun, terdapat beberapa deviasi besar pada periode tertentu, terutama ketika nilai aktual sangat rendah atau berubah tajam sementara prediksi model masih mengikuti pola operasi sebelumnya. Kondisi ini menjelaskan mengapa test RMSE lebih tinggi daripada test MAE. Perbandingan aktual dan prediksi juga ditampilkan dalam bentuk *scatter plot* pada Gambar 10.



Gambar 10. *Scatter* aktual vs prediksi

Gambar 10 menunjukkan bahwa sebagian besar titik *validation* dan test berada dekat dengan garis ideal $\hat{y} = y$. Kedekatan titik terhadap garis ideal menunjukkan bahwa model menghasilkan estimasi yang searah dengan nilai aktual. Titik yang menjauh dari garis ideal merepresentasikan periode dengan residual besar, terutama saat target aktual berada pada nilai rendah atau berubah secara tajam.

H. Pembahasan Metrik Performa

- 1) *Interpretasi R^2* : Nilai R^2 digunakan untuk melihat proporsi variasi target yang dapat dijelaskan oleh model. Model memperoleh R^2 train sebesar 0,8953, *validation* sebesar 0,9886, dan test sebesar 0,9121. Nilai test R^2 yang tetap berada di atas 0,9 menunjukkan bahwa model memiliki kemampuan generalisasi yang baik pada data *holdout*. Tidak tampak indikasi *overfitting* ekstrem jika dilihat dari R^2 , karena performa pada data *test* tetap tinggi.
- 2) *Interpretasi RMSE dan MAE*: RMSE dan MAE digunakan untuk menilai besar kesalahan pada skala target asli. Pada data *test*, RMSE sebesar 5,1981 lebih tinggi daripada MAE sebesar 2,7517. Perbedaan ini menunjukkan bahwa sebagian besar error berada pada

tingkat yang relatif lebih kecil, tetapi terdapat beberapa titik dengan error besar. Karena RMSE memberi penalti kuadrat terhadap error besar, keberadaan beberapa residual ekstrem dapat meningkatkan RMSE secara signifikan.


- 3) *Interpretasi Bias*: Bias test bernilai 1,2557, sehingga prediksi C2H6 pada data *test* secara rata-rata sedikit lebih tinggi daripada nilai aktual. Bias positif ini perlu diperhatikan apabila model digunakan sebagai *soft sensor* karena kecenderungan *over-estimate* dapat membuat kondisi proses tampak lebih tinggi daripada kondisi aktual. Namun, signifikansi praktis nilai bias tersebut tetap perlu dibandingkan dengan toleransi operasi dan kebutuhan monitoring di lapangan.
- 4) *Perbandingan Split*: Perbandingan antar-*split* menunjukkan bahwa performa model konsisten, tetapi tidak identik pada setiap periode kronologis. Test RMSE lebih tinggi daripada *validation* RMSE, yaitu 5,1981 dibandingkan 3,5466, sedangkan test R^2 lebih rendah daripada *validation* R^2 , yaitu 0,9121 dibandingkan 0,9886. Hal ini menunjukkan bahwa periode *test* lebih menantang dibandingkan periode *validation*, khususnya karena terdapat beberapa titik dengan residual besar.

I. Analisis Residual dan Sumber Error

Analisis residual digunakan untuk melihat pola kesalahan yang tidak selalu terlihat dari metrik rata-rata. Ringkasan residual pada setiap *split* ditunjukkan pada Tabel XIV.

TABEL XIV
METRIK PERFORMA MODEL TERBAIK

<i>Split</i>	Rata-rata residual / Bias	Std residual	Residual minimum	Residual maksimum	Median absolut error	P90 absolut error
<i>Train</i>	0,4396	3,1114	-19,6530	37,7137	1,8274	4,7245
<i>Validation</i>	-0,4844	3,5191	-14,4722	20,3140	2,2765	4,8518
<i>Test</i>	1,2557	5,0524	-8,7788	56,3520	2,0015	5,1261



Gambar 11. Residual test terhadap waktu dan histogram residual

Gambar 11 menunjukkan residual data *test* terhadap waktu dan distribusi residualnya. Sebagian besar residual berada di

sekitar nol, yang berarti model tidak terus-menerus menyimpang jauh dari nilai aktual. Namun, terdapat beberapa residual positif yang besar. Temuan ini konsisten dengan bias test yang positif dan perbedaan antara RMSE dan MAE. Titik residual terbesar pada data *test* ditunjukkan pada Tabel XV.

TABEL XV
TITIK RESIDUAL *TEST* TERBESAR

Waktu	Aktual	Prediksi	Residual	Absolut error
2023-10-28 15:08	0,0000	56,3520	56,3520	56,3520
2023-10-28 22:08	26,5600	67,9678	41,4078	41,4078
2023-11-17 22:08	52,5700	65,6135	13,0435	13,0435

Galat terbesar terjadi saat nilai C2H6 berada pada tingkat sangat rendah atau mengalami perubahan tajam, sehingga verifikasi tambahan melalui catatan operasi diperlukan untuk memastikan apakah kondisi tersebut merupakan operasi sah, *transient*, atau anomali pencatatan. *Residual* kecil di sebagian besar titik menandakan model mampu mengikuti pola operasi normal, sedangkan *residual* besar menunjukkan kelemahan model dalam menghadapi perubahan mendadak atau pola target yang jarang muncul pada data pelatihan.

J. Relevansi Model sebagai Soft Sensor

Hasil eksperimen menunjukkan bahwa LSTM memiliki potensi sebagai *baseline soft sensor* untuk estimasi C2H6 pada unit *Deethanizer Column Plant 3 Train G*. *Soft sensor* relevan karena pengukuran komposisi tidak selalu tersedia secara kontinu, dapat memiliki jeda waktu, atau bergantung pada instrumen/*analyzer* khusus. Dengan memanfaatkan variabel proses seperti temperatur, tekanan, laju alir, dan level, model dapat menyediakan estimasi berbasis pola historis proses. Relevansi model terhadap kebutuhan *soft sensor* dirangkum pada Tabel XVI.

TABEL XVI
IMPLIKASI HASIL TERHADAP PENGGUNAAN *SOFT SENSOR*

Temuan	Implikasi
Test $R^2 = 0,9121$	Model mampu menangkap sebagian besar variasi C2H6 pada data <i>holdout</i> .
Test RMSE = 5,1981	Masih terdapat error absolut yang perlu dibandingkan dengan batas toleransi operasi.
Test MAE = 2,7517	Rata-rata error absolut relatif lebih kecil daripada RMSE, sehingga sebagian besar error tidak sebesar outlier residual.
Bias test = 1,2557	Model sedikit cenderung <i>over-estimate</i> pada data <i>test</i> .
Residual besar pada periode tertentu	Model memerlukan validasi tambahan pada kondisi <i>transient</i> , target rendah, atau perubahan proses tajam.
Konfigurasi terbaik menggunakan 2 layer dan <i>dropout</i> 0,2	Penambahan kedalaman LSTM dan regularisasi <i>dropout</i> membantu performa pada eksperimen ini.

Berdasarkan Tabel XVI, model layak dipertimbangkan sebagai alat bantu monitoring atau decision-support. Namun, model belum dapat langsung diposisikan sebagai pengganti final analyzer tanpa validasi operasional lanjutan. Penggunaan di lapangan tetap membutuhkan perbandingan dengan toleransi proses, pengujian pada data real-time, dan validasi bersama engineer operasi.

K. Keterbatasan Interpretasi Hasil

Interpretasi hasil pada bab ini memiliki beberapa batasan agar klaim penelitian tetap proporsional. Keterbatasan tersebut ditunjukkan pada Tabel XVII.

TABEL XVII
KETERBATASAN INTERPRETASI HASIL

Keterbatasan	Dampak terhadap interpretasi
Evaluasi dilakukan secara <i>offline</i>	Hasil menunjukkan performa historis, belum membuktikan performa <i>real-time</i> .
Belum dibandingkan dengan toleransi operasi	Nilai RMSE, MAE, dan bias belum dapat dinyatakan pasti memenuhi kebutuhan operasi.
Periode transient belum dipisahkan secara khusus	Error besar belum dapat dikaitkan secara final dengan <i>startup</i> , <i>shutdown</i> , <i>upset</i> , atau perubahan operasi tanpa data operasi tambahan.
Interpretasi tag proses belum diselaraskan dengan P&ID secara rinci	Pembahasan proses dibatasi pada tipe umum variabel seperti temperatur, tekanan, laju alir, dan level.
Fokus penelitian LSTM-only	Hasil tidak digunakan untuk mengklaim bahwa LSTM lebih baik daripada seluruh model lain di luar ruang lingkup penelitian.
Validasi <i>analyzer</i> /lab belum dibahas terpisah	Keandalan target historis diasumsikan mengikuti data yang tersedia pada dataset.

Keterbatasan tersebut tidak mengurangi nilai eksperimen sebagai pembuktian awal pengembangan *soft sensor* berbasis LSTM. Namun, keterbatasan ini menunjukkan bahwa pengujian lanjutan tetap diperlukan sebelum model digunakan sebagai sistem monitoring operasional secara langsung.

L. Ringkasan Hasil dan Pembahasan

Konfigurasi terbaik berupa LSTM dua lapis dengan *dropout* 0,2 berhasil meningkatkan performa model awal, menghasilkan nilai R^2 validasi 0,9886 dan uji 0,9121. Model mampu mengikuti tren utama C2H6 dengan mayoritas *residual* berada di kisaran nol, meskipun deviasi besar masih ditemukan pada beberapa periode. Hasil ini menunjukkan potensi LSTM sebagai *baseline soft sensor* untuk estimasi C2H6 pada *Deethanizer Column Plant 3 Train G*, dengan catatan implementasi operasional tetap memerlukan validasi lanjutan terhadap data *real-time*.

IV. KESIMPULAN

Berdasarkan pelaksanaan penelitian, hasil eksperimen, dan pembahasan yang telah dilakukan, dapat disimpulkan beberapa hal sebagai berikut

1. Penelitian ini berhasil mengembangkan model *soft sensor* berbasis *Long Short-Term Memory* (LSTM)

untuk mengestimasi kandungan etana (C2H6) pada unit *Deethanizer Column Plant 3 Train G*. Model dibangun menggunakan data historis operasi proses yang terdiri atas 13 variabel input, yaitu variabel laju aliran, level, tekanan, dan temperatur. Data tersebut diperlakukan sebagai data deret waktu sehingga proses pembagian data dan pembentukan *sequence* dilakukan secara kronologis.

2. Tahapan pra-pemrosesan data dilakukan dengan menjaga urutan waktu pengamatan. Data dibagi menjadi 70% data *train*, 15% data *validation*, dan 15% data *test*. Pembagian kronologis ini penting karena model ditujukan untuk mempelajari pola historis sebelum titik prediksi, bukan menggunakan informasi dari periode masa depan. Target C2H6 tidak diimputasi, dan pada dataset penelitian tidak terdapat nilai target kosong.
3. Konfigurasi model terbaik diperoleh dari LSTM dua layer dengan *dropout* 0,2, *hidden size* 32, dan panjang *lookback* 36 *timestep*. Konfigurasi ini menghasilkan performa terbaik berdasarkan *validation* R^2 , yaitu 0,9886. Hasil ini menunjukkan bahwa penambahan kedalaman model dan regularisasi *dropout* membantu model menangkap hubungan temporal pada data proses yang digunakan.
4. Pada data *test*, model terbaik menghasilkan R^2 sebesar 0,9121, RMSE sebesar 5,1981, MAE sebesar 2,7517, dan bias sebesar 1,2557. Nilai test R^2 tersebut menunjukkan bahwa model mampu menjelaskan sebagian besar variasi C2H6 pada data *holdout*. Sementara itu, nilai bias positif menunjukkan bahwa prediksi model pada periode uji sedikit cenderung lebih tinggi dibandingkan nilai aktual.
5. Analisis grafik aktual dan prediksi menunjukkan bahwa model LSTM mampu mengikuti tren utama C2H6, baik pada data *validation* maupun data *test*. Namun, masih terdapat beberapa deviasi besar, terutama ketika nilai aktual C2H6 sangat rendah atau berubah tajam. Kondisi tersebut terlihat pada analisis residual, yaitu adanya beberapa residual positif besar yang meningkatkan nilai RMSE.
6. Berdasarkan hasil tersebut, LSTM memiliki potensi sebagai *baseline soft sensor* untuk estimasi C2H6 pada unit *Deethanizer Column Plant 3 Train G*. Model dapat menjadi alat bantu awal untuk monitoring berbasis data historis, khususnya ketika pengukuran komposisi tidak tersedia secara kontinu atau membutuhkan waktu tunggu dari instrumen/analyzer. Meskipun demikian, model belum dapat langsung diposisikan sebagai pengganti analyzer tanpa validasi operasional lanjutan.

UCAPAN TERIMA KASIH

Penulis ingin mengucapkan terimakasih kepada berbagai pihak yang telah membantu dan memberikan dukungan dalam berbagai bentuk. Tiga diantaranya yaitu Bapak Prof. Ir. Nazrul Effendy, S.T., M.T., Ph.D., IPM., Bapak Dr. Eng. Ir. Dwi Joko

Suroso, S.T., M.Eng., IPP., dan Badak LNG Bontang selaku dosen pembimbing utama, dosen pembimbing pendamping, dan perusahaan dalam penyelesaian Tugas Akhir penulis yang telah memberikan banyak bimbingan, dukungan, & motivasi dalam pengerjaan Tugas Akhir.

REFERENSI

- [1] Suwandono, "Meningkatkan Ketersediaan Ethana Refrigerant dengan Memanfaatkan Overhead Vapor Kolom Deethanizer Sebagai Bahan Refrigerant di Kilang Badak LNG Bontang," Badak LNG, Bontang, Kalimantan Timur, 2023.
- [2] W. Q. Al-Bukhaiti, A. Noman, A. S. Qasim, and A. Al-Farga, "Gas Chromatography: Principles, Advantages and Applications in Food Analysis," *IJAIR*, vol. 6, no. 1, pp. 123–128, Jul. 2017, Accessed: Aug. 17, 2025. [Online]. Available: https://www.researchgate.net/publication/342360886_Gas_Chromatography_Principles_Advantages_and_Applications_in_Food_Analysis
- [3] Badak LNG, "Instrument Module # 09: Analyzers." Badak LNG.
- [4] W. Y. Moon and S. D. Kim, "A Framework of Soft Sensor Systems with Machine Learning," in *2022 International Conference on Computational Science and Computational Intelligence (CSCI)*, Dec. 2022, pp. 153–159. doi: 10.1109/CSCI58124.2022.00031.
- [5] I. Ahmad, A. Ayub, M. Kano, and I. I. Cheema, "Gray-box Soft Sensors in Process Industry: Current Practice, and Future Prospects in Era of Big Data," *Processes*, vol. 8, no. 2, p. 243, Feb. 2020, doi: 10.3390/pr8020243.
- [6] Ž. Ujević Andrijić, N. Rimac, and I. Martić, "Development of a Soft Sensor in a Propylene Production Plant," *Engineering Power : Bulletin of the Croatian Academy of Engineering*, vol. 18, no. 4, pp. 7–15, 2023, Accessed: Oct. 06, 2025. [Online]. Available: <https://hrcak.srce.hr/327427>
- [7] N. Sifakis, N. Sarantinoudis, G. Tsinarakis, C. Politis, and G. Arampatzis, "Soft Sensing of LPG Processes Using Deep Learning," *Sensors*, vol. 23, no. 18, p. 7858, Jan. 2023, doi: 10.3390/s23187858.
- [8] J. G. Gallareta, C. González-Menorca, P. Muñoz, and M. V. Vasic, "Advancements in Soft-Sensor Technologies for Quality Control in Process Manufacturing: A Review," *IEEE Sensors Journal*, vol. 25, no. 9, pp. 14575–14588, May 2025, doi: 10.1109/JSEN.2025.3549596.
- [9] I. H. Sarker, "Deep Learning: A Comprehensive Overview on Techniques, Taxonomy, Applications and Research Directions," *SN Comput Sci*, vol. 2, no. 6, p. 420, 2021, doi: 10.1007/s42979-021-00815-1.
- [10] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Comput*, vol. 9, no. 8, pp. 1735–1780, Nov. 1997, doi: 10.1162/neco.1997.9.8.1735.
- [11] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015, doi: 10.1038/nature14539.
- [12] W. Li, G. Wang, and J. Ma, "Deep learning for complex chemical systems," *Natl Sci Rev*, vol. 10, no. 12, p. nwad335, Dec. 2023, doi: 10.1093/nsr/nwad335.
- [13] E. D. Kurniawan, "Soft Sensor Berbasis Xtreme Gradient Boosting Untuk Prediksi Nilai Kandungan Oksigen Dalam Flue Gas Pada Boiler PT. Pertamina RU V Balikpapan," Skripsi, Universitas Gadjah Mada, Yogyakarta, 2021.
- [14] F. N. Yuanto, "Perancangan Soft Sensor Berbasis Extreme Gradient Boosting Untuk Prediksi Konsentrasi NH3 Pada Unit Kristalizer di Urea Plant I-B PT Pusri Palembang," Skripsi, Universitas Gadjah Mada, Yogyakarta, 2023.
- [15] M. Mandis, R. Baratti, J. Chebeir, S. Tronci, and J. A. Romagnoli, "Exploring nontraditional LSTM architectures for modeling demethanizer column operations," *Computers & Chemical Engineering*, vol. 183, p. 108591, Apr. 2024, doi: 10.1016/j.compchemeng.2024.108591.